Sveučilište u Splitu
Fakultet elektrotehnike, strojarstva i brodogradnje

Laboratorijske vježbe iz
digitalne obrada i analiza slike

Vježba 6:

Segmentacija digitalne slike

Split, 2020.

Zadatak 1.

U Pythonu učitajte sliku u razinama sive boje i napišite funkciju koja će je segmentirati na slijedeći način:

- klasa 1 - svi pikseli u rangu [0, 85]
- klasa 2 - svi pikseli u rangu [86, 171]
- klasa 3 - svi pikseli u rangu [172, 255]

Originalna slika:

Segmentirana slika:

Kod:

```
import cv2

slika=cv2.imread('../img/img_greyscale.jpg')

retci=slika.shape[0]
stupci=slika.shape[1]
kanali=slika.shape[2]

for k in range(0, kanali):
    for i in range(0, retci):
        for j in range(0, stupci):

            if slika[i, j, k] >= 172 and slika[i, j, k] <= 225:
                slika[i, j, k] = 255
            elif slika[i, j, k] >= 86 and slika[i, j, k] <= 171:
                slika[i, j, k] = 150
            else:
                slika[i, j, k] = 0

cv2.imwrite('../img/img_z1.jpg', slika)
```

Zadatak 2.

U Pythonu učitajte sliku u boji i na nju primijenite algoritam k-sredina (ne trebate ga sami implementirati, možete koristiti postojeću funkciju). Kako se segmentirana slika i brzina algoritma mijenjaju kada se mijenja k?

Odgovor:
Što je k veći, proces je sporiji ali i s razlogom jer uvodimo više segmenata, odnosno, što je k manji, manje je segmenata (cjelina) pa će proces bit brži. U konačnici o veličini k ovisi hoćemo li imat jednobojnu sliku, ili „višebojnu“ tj. hoće li slika sličiti izvornoj s detaljima tj. sa jako puno segmenata ili će imati manji broj segmenata pa s time sličiti više na binarnu sliku ili na jednobojnu cjelinu.

Originalna slika:

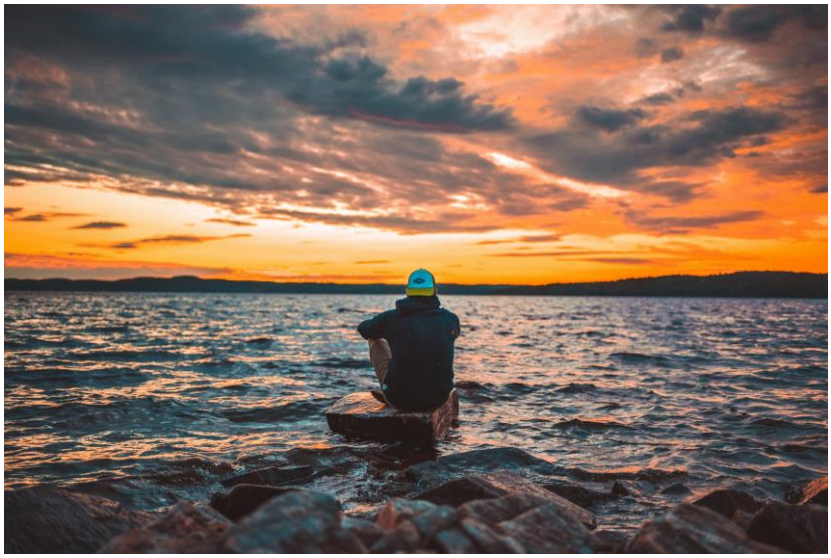

Segmentirana slika:

Kod:

```
import numpy as np
import matplotlib.pyplot as plt
import cv2

image = cv2.imread("../img/img.jpg")

pixel_vals = image.reshape((-1, 3))

pixel_vals = np.float32(pixel_vals)

criteria = (cv2.TERM_CRITERIA_EPS + cv2.TERM_CRITERIA_MAX_ITER, 100, 0.85)

k = 5

retval, labels, centers = cv2.kmeans(pixel_vals, k, None, criteria, 10, cv2.KM
EANS_RANDOM_CENTERS)

centers = np.uint8(centers)
segmented_data = centers[labels.flatten()]
segmented_image = segmented_data.reshape((image.shape))

cv2.imwrite('../img/img_z2.jpg', segmented_image)
```

Zadatak 3.

U Pythonu učitajte sliku u boji i na nju primijenite algoritam razvodnjavanja (ne trebate ga sami implementirati, možete koristiti postojeću funkciju). Usporedite dobivenu segmentiranu sliku sa rezultatima iz prethodnog zadatka.

Odgovor:
Ako je kod napravio što je trebao, jako je loše odredio segmente te mi se čini da je postupak iz 2. zadatka učinkovitiji.

Originalna slika:

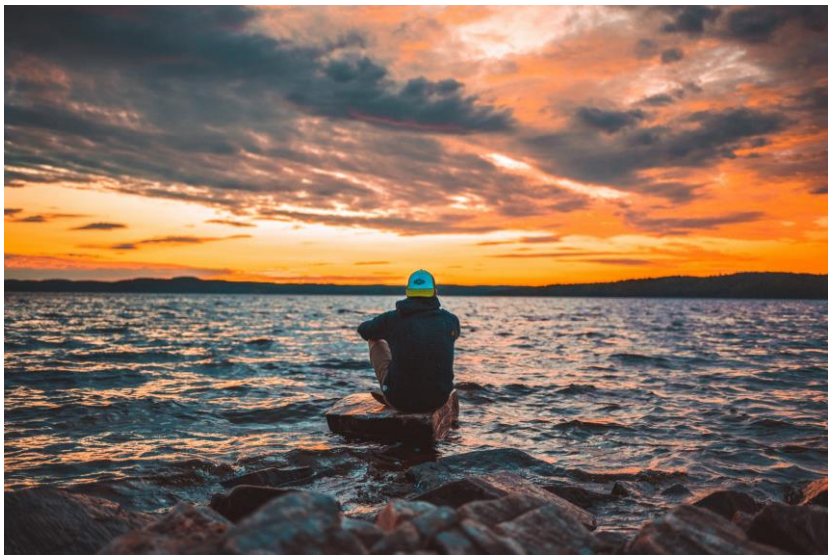

Segmentirana slika:

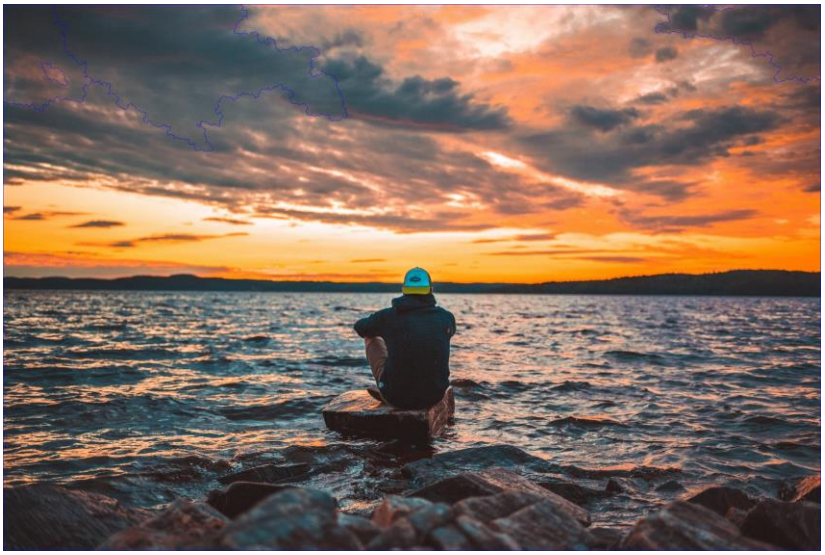

Kod:

```
import numpy as np
import cv2 as cv
from matplotlib import pyplot as plt

img = cv.imread('../img/img.jpg')
gray = cv.cvtColor(img, cv.COLOR_BGR2GRAY)
ret, thresh = cv.threshold(gray, 0, 255, cv.THRESH_BINARY_INV + cv.THRESH_OTSU
)

# noise removal
kernel = np.ones((3,3), np.uint8)
opening = cv.morphologyEx(thresh, cv.MORPH_OPEN, kernel, iterations = 2)
# sure background area
sure_bg = cv.dilate(opening, kernel, iterations=3)
# Finding sure foreground area
dist_transform = cv.distanceTransform(opening, cv.DIST_L2, 5)
ret, sure_fg = cv.threshold(dist_transform, 0.7 * dist_transform.max(), 255, 0
)
# Finding unknown region
sure_fg = np.uint8(sure_fg)
unknown = cv.subtract(sure_bg, sure_fg)

# Marker labelling
ret, markers = cv.connectedComponents(sure_fg)
# Add one to all labels so that sure background is not 0, but 1
markers = markers + 1
# Now, mark the region of unknown with zero
markers[unknown == 255] = 0

markers = cv.watershed(img, markers)
img[markers == -1] = [255, 0, 0]

cv.imwrite('../img/img_z3.jpg', img)
```